

# Proyecto 2: Análisis de señales ECG y detección de arritmias - análisis espectral

1<sup>st</sup> Dina Yared Parra Romero  
*Universidad de Antioquia*  
Medellín, Colombia  
dina.parra@udea.edu.co

3<sup>rd</sup> Cristian Tamayo Arango  
*Universidad de Antioquia*  
Medellín, Colombia  
cristian.tamayoa@udea.edu.co

2<sup>nd</sup> Carolina Ruiz Morales  
*Universidad de Antioquia*  
Medellín, Colombia  
carolina.ruizm@udea.edu.co

**Resumen** Este trabajo presenta un análisis comparativo de señales electrocardiográficas (ECG) con el objetivo de detectar patrones asociados a arritmias cardíacas, mediante la extracción de características espectrales. Se emplearon tres enfoques: la Transformada Discreta de Fourier (DFT), la Transformada Discreta del Coseno (DCT) y los Coeficientes Cepstrales en Frecuencia de Mel (MFCC), sobre un conjunto de datos clínicos etiquetado. Posteriormente, se evaluó la capacidad discriminativa de cada característica entre diferentes tipos de ritmo cardíaco, con énfasis en la diferenciación entre ritmos normales (SR) y patológicos (AFIB). Los resultados muestran que características como la entropía y la energía espectral presentan diferencias estadísticamente significativas entre grupos, lo que demuestra su utilidad como posibles biomarcadores computacionales. Este análisis se complementó con pruebas de hipótesis y se contrastó con literatura especializada [1] [4].

## I. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) constituyen la principal causa de muerte a nivel mundial, cobrando aproximadamente 17.9 millones de vidas cada año [1]. Entre estas, las arritmias cardíacas representan un grupo relevante de alteraciones en el ritmo del corazón, que pueden ir desde manifestaciones benignas hasta condiciones potencialmente mortales como la fibrilación auricular (AFIB), la taquicardia supraventricular (SVT) o la bradicardia sinusal. El diagnóstico temprano de estas condiciones es esencial para prevenir complicaciones graves como accidentes cerebrovasculares e insuficiencia cardíaca congestiva [1] [2].

El electrocardiograma (ECG) es una herramienta diagnóstica fundamental, ampliamente utilizada para registrar la actividad eléctrica del corazón. Permite detectar alteraciones en el ciclo cardíaco como las ondas P, complejos QRS y ondas T, cuyos cambios morfológicos o temporales pueden indicar patologías específicas [2]. Sin embargo, la interpretación del ECG aún depende en gran medida del juicio clínico, lo que puede generar diferencias en la interpretación entre distintos profesionales de la salud, especialmente en ambientes con recursos limitados. Ante esta necesidad, en los últimos años se ha incrementado el desarrollo de sistemas computacionales para el análisis automatizado de señales ECG. Estos sistemas

aplican algoritmos de procesamiento de señales y aprendizaje automático para extraer características relevantes que permitan clasificar los distintos ritmos cardíacos con alta precisión. Dentro de estos enfoques, los métodos basados en análisis espectral han mostrado ser particularmente efectivos para capturar patrones temporales y frecuenciales asociados a distintas arritmias [3].

La Transformada Discreta de Fourier (DFT) ha sido ampliamente utilizada en estudios clínicos para identificar la frecuencia dominante de la señal, que en el caso del ECG, puede reflejar tanto la tasa cardíaca como variaciones rítmicas anómalas [4]. Por su parte, la Transformada Discreta del Coseno (DCT) ha demostrado ser eficaz para la compresión de datos y la extracción de componentes significativos, especialmente útil para representar la señal ECG con una menor redundancia [4] [5]. Más recientemente, técnicas inspiradas en el procesamiento de la voz como los Coeficientes Cepstrales en Frecuencia de Mel (MFCC) han sido adaptadas al análisis de señales biológicas. Su capacidad para modelar la energía distribuida en bandas frecuenciales perceptualmente relevantes los convierte en una herramienta robusta para el reconocimiento de patrones en ECG [5].

En este estudio se implementan y comparan tres métodos para extraer información relevante de señales ECG: la Transformada Discreta de Fourier (DFT), la Transformada Discreta del Coseno (DCT) y los Coeficientes Cepstrales en las Frecuencias de Mel (MFCC). El objetivo es identificar cuáles de estas técnicas permiten distinguir mejor entre ritmos normales del corazón (SR) y arritmias como la fibrilación auricular (AFIB). Para ello, se analiza una base de datos clínica utilizando gráficos estadísticos y pruebas inferenciales. Además, este trabajo se inspira en investigaciones previas que han demostrado la utilidad de los métodos espectrales para apoyar el diagnóstico automático de ritmos cardíacos [4] [6].

## II. CORRECCIONES PROYECTO 1

### A. Analisis 3: subseccion 4

Como análisis adicional, se propone una comparación y aplicación complementaria de las librerías py-ecg-detectors y

NeuroKit2 (nk2), aprovechando sus capacidades específicas para enriquecer el estudio de señales electrocardiográficas, particularmente para ritmos cardíacos normales (SR) y patológicos (AFIB). Ambas librerías permiten la detección de picos R, pero difieren en su enfoque, nivel de detalle y posibilidades analíticas.

La librería py-ecg-detectors está diseñada para implementar múltiples algoritmos de detección de complejos QRS, como Pan-Tompkins, Hamilton, Engzee y Christov. Estos métodos han sido validados en literatura para su uso en tiempo real, siendo especialmente útiles en aplicaciones donde se requiere alta velocidad de procesamiento. Por su parte, NeuroKit2 ofrece una solución más integral, ya que no solo permite la detección de picos R mediante `ecg_peaks`, sino también la identificación completa de las ondas P, Q, R, S y T, así como el cálculo automático de métricas de variabilidad del ritmo cardíaco (HRV), análisis espectrales, y herramientas de visualización.

Basado en estas diferencias, se propone como primer análisis adicional el estudio de la variabilidad del ritmo cardíaco (HRV) utilizando nk2. Esta herramienta permite calcular parámetros clásicos como SDNN, RMSSD, pNN50, así como métricas espectrales como el cociente LF/HF, lo cual es relevante debido a que la fibrilación auricular se caracteriza por una alta irregularidad de los intervalos RR. Este tipo de análisis ha sido ampliamente respaldado en la literatura como un indicador fiable de disfunción autonómica y alteraciones cardíacas [23] [24].

En segundo lugar, se plantea utilizar py-ecg-detectors para evaluar la robustez de distintos algoritmos de detección de picos R frente a condiciones adversas, como presencia de artefactos o ruido de fondo. Por ejemplo, el algoritmo de Engzee ha demostrado un desempeño superior en situaciones de señal no ideal [26]. Esta comparación puede realizarse cuantificando diferencias en la localización de picos R respecto a anotaciones manuales o en comparación con los resultados de `nk.ecg_peaks()`, lo cual permitiría seleccionar el mejor método para futuras aplicaciones clínicas o académicas.

Finalmente, se sugiere un análisis morfológico de las ondas ECG utilizando la función `nk.ecg_delineate()`, que permite extraer duraciones de segmentos PR, QRS y QT. Estas medidas son fundamentales para la evaluación de la conducción eléctrica cardíaca y la detección de posibles anomalías como el ensanchamiento del QRS o alteraciones en el intervalo QT, asociados a riesgo de arritmias [27], [28]. Comparar estos parámetros entre señales de pacientes con ritmo sinusal y fibrilación auricular podría aportar información adicional sobre las diferencias fisiológicas subyacentes entre ambos grupos.

#### *B. Analisis 4: subseccion 3 y 4*

La librería `hrvanalysis` está específicamente orientada al análisis cuantitativo de HRV. Ofrece funciones para calcular métricas de dominio temporal (como SDNN, RMSSD, NN50, pNN50), de dominio frecuencial (mediante transformadas de Fourier o Wavelet) y de medidas no lineales (como entropía aproximada o Poincaré). Estas métricas están ampliamente

respaldadas por la literatura para evaluar el balance simpático-parasimpático [24] y su alteración se ha asociado con diversas condiciones clínicas, incluyendo enfermedades cardiovasculares, estrés crónico y deterioro del estado físico [31].

Por otro lado, NeuroKit2 se destaca por ser una librería integral para el análisis de señales fisiológicas, entre ellas ECG. Además de ofrecer todas las métricas clásicas de HRV, también permite la pre-procesamiento automatizado de señales, detección robusta de picos R con funciones como `nk.ecg_peaks`, y la visualización integrada de resultados. Esto la convierte en una herramienta más accesible y completa para estudios que requieren análisis exploratorio o integración de múltiples señales fisiológicas simultáneamente [32]. Asimismo, `nk.hrv()` encapsula en una sola llamada una batería completa de métricas HRV, lo cual simplifica la implementación sin comprometer el rigor metodológico.

Desde una perspectiva comparativa, `hrvanalysis` ofrece mayor flexibilidad cuando se desea personalizar cada etapa del procesamiento, por ejemplo, el tipo de interpolación, filtrado o selección de ventanas, lo cual puede ser ventajoso para investigadores avanzados que deseen controlar cada parámetro del análisis. En contraste, NeuroKit2 favorece la estandarización y automatización, aspectos clave cuando se trabaja con grandes volúmenes de datos o cuando se necesita garantizar la reproducibilidad del análisis. En términos de validación, ambas librerías se alinean con los lineamientos internacionales para el análisis de HRV, como los propuestos por la [33].

Como análisis adicional, se propone una evaluación comparativa entre las librerías `hrvanalysis` y NeuroKit2 en el contexto del análisis de la variabilidad de la frecuencia cardíaca (HRV), con el fin de determinar cuál de estas herramientas ofrece mayor precisión, versatilidad y valor interpretativo para los datos ECG utilizados. Dado que la HRV es un marcador fundamental de la regulación autonómica del sistema cardiovascular y se ve significativamente alterada en condiciones como la fibrilación auricular (AFIB), una caracterización confiable de este parámetro es crucial para los fines del presente trabajo.

### III. METODOLOGÍA

#### *A. Datos*

Se utilizó la base de datos Chapman ECG, que incluye señales preprocesadas (denoised) y anotaciones clínicas asociadas (archivo `Diagnostics.xlsx`). Se seleccionaron los registros correspondientes a los ritmos AFIB y SR, por su relevancia clínica y suficiencia estadística.

#### *B. Extraccion de características*

1) *Transformada Discreta de Fourier (DFT)*: esta se aplicó utilizando la función `scipy.fft : fft, fftfreq`, transformando la señal del dominio temporal al frecuencial. Se extrajeron las siguientes características:

- **Frecuencia pico** (`peak_freq`): componente de mayor magnitud espectral, representativa del ritmo dominante.

- **Energía total** (`total_energy`): suma de los cuadrados de los coeficientes de la DFT:

$$E_{\text{total}} = \sum_{k=0}^{N-1} |X[k]|^2$$

donde  $X[k]$  son los coeficientes de la DFT y  $N$  es la longitud de la señal.

- **Número de armónicos significativos**: cantidad de picos relevantes, asociada a la complejidad de la señal.
- **Relación armónica** ( $H2/H1$ ): cociente entre el segundo y primer armónico, como indicador de irregularidad:

$$H2/H1 = \frac{|X[2]|}{|X[1]|}$$

En primer lugar, se implementó el Algoritmo 8 [4], mediante el cual se importó la señal ECG, se aplicó un preprocesamiento basado en normalización y filtrado pasa banda (1–40 Hz), y posteriormente se calculó la Transformada Rápida de Fourier (FFT) utilizando la librería `scipy.fft`, con el objetivo de convertir las señales ECG del dominio temporal al dominio frecuencial. En primer lugar, se calculó la FFT de la señal (`yf = fft(ecg)`), lo cual permitió obtener la representación espectral completa. Posteriormente, se generaron las frecuencias correspondientes (`xf = fftfreq(n, 1 / fs)`) a partir de la longitud de la señal ( $n$ ) y la frecuencia de muestreo ( $fs$ ). Debido a la simetría de la FFT, se consideró únicamente el espectro positivo (`positive_freqs = xf[:n // 2]`). A partir de este, se extrajeron la magnitud (`magnitude = np.abs(yf[:n // 2])`) y la fase (`phase = np.angle(yf[:n // 2])`) de cada componente frecuencial, representando la amplitud y el desplazamiento angular de cada senoide.

La descomposición espectral permitió obtener métricas relevantes para el análisis de señales ECG. Se calculó la frecuencia del pico espectral (`peak_freq`), la cual reflejó el componente dominante de frecuencia en la señal, útil para identificar patrones rítmicos característicos de arritmias como la fibrilación auricular, que tiende a presentar espectros más difusos y con menor concentración de energía en una sola frecuencia dominante [12]. Asimismo, se estimó la energía total (`total_energy`) en el dominio de la frecuencia, la cual ofreció una medida de la actividad eléctrica global del corazón, útil para distinguir entre señales de bajo voltaje, como en miocardiopatías, y señales de ritmos normales o taquiarritmias [13].

También se cuantificó el número de armónicos significativos (`num_harmonics`), que representó la complejidad estructural de la señal ECG; este valor tendió a incrementarse en arritmias complejas, asociadas a una activación miocárdica desorganizada [13]. Finalmente, se evaluó la relación entre la magnitud del segundo armónico y la del primero, la cual aportó información sobre la regularidad de la señal: una relación elevada se asoció con señales más complejas e irregulares, típicas de ritmos cardíacos anómalos.

2) *Transformada Discreta del Coseno (DCT)*: Se calculó la DCT mediante `scipy.fftpack.dct`, obteniendo una

representación compacta en términos de funciones coseno. Se extrajeron las siguientes métricas:

- **Media y desviación estándar**:

$$\mu = \frac{1}{N} \sum_{i=0}^{N-1} x[i], \quad \sigma = \sqrt{\frac{1}{N} \sum_{i=0}^{N-1} (x[i] - \mu)^2}$$

donde  $x[i]$  son los coeficientes DCT y  $N$  es la longitud de la señal.

- **Asimetría (skewness) y curtosis (kurtosis)**:

$$\text{Skewness} = \frac{\frac{1}{N} \sum_{i=0}^{N-1} (x[i] - \mu)^3}{\sigma^3}; \quad \text{Kurtosis} = \frac{\frac{1}{N} \sum_{i=0}^{N-1} (x[i] - \mu)^4}{\sigma^4}$$

- **Energía espectral**:

$$E = \sum_{i=0}^{N-1} |x[i]|^2$$

- **Entropía**:

$$H = - \sum_{i=0}^{N-1} p(x[i]) \log_2 p(x[i])$$

donde  $p(x[i])$  es la probabilidad del coeficiente  $x[i]$ .

Conforme al Algoritmo 9 [4], se realizó un análisis espectral basado en la Transformada Discreta del Coseno (DCT) aplicada sobre ventanas centradas en los picos R, correspondientes a cada latido cardíaco. La detección de dichos picos se efectuó utilizando la librería `NeuroKit2`. Dado que el electrocardiograma (ECG) es una señal continua, se segmentó en ventanas de 500 milisegundos (equivalente a 500 muestras a 500 Hz), lo que permitió estudiar individualmente la dinámica de cada latido.

En una segunda etapa, se aplicó la autocorrelación a cada ventana (paso 4 del Algoritmo 9), con el objetivo de resaltar la estructura repetitiva de la señal alrededor del complejo QRS y las ondas P y T. Esta operación generó una señal simétrica que fortaleció los patrones dominantes del latido, al tiempo que atenuó el ruido de alta frecuencia, mejorando así la robustez del análisis posterior.

A continuación, sobre la señal autocorrelada, se aplicó la DCT tipo II (paso 5 del Algoritmo 9), que permitió transformar la señal al dominio frecuencial utilizando funciones coseno ortogonales. Se conservaron los primeros 50 coeficientes DCT, por ser los que concentran la mayor parte de la energía espectral relevante del latido, descartando coeficientes de orden superior que generalmente corresponden a ruido o variaciones menores.

Respecto a las métricas extraídas, se calcularon la media y desviación estándar de los coeficientes DCT, las cuales reflejan la tendencia central y la dispersión de la energía espectral de la señal ECG. Estas métricas resultan útiles para la clasificación de arritmias, ya que permiten identificar alteraciones en la morfología que caracterizan diferentes condiciones cardíacas [11]. Además, se evaluaron la asimetría (skewness) y la curtosis (kurtosis) del vector de coeficientes, que proporcionan

información sobre la forma de la distribución espectral. Estas características han sido empleadas exitosamente para detectar patrones anómalos en señales ECG, como los presentes en arritmias ventriculares o supraventriculares [12].

Por último, se calcularon dos métricas globales: la energía, que cuantifica la potencia total de la señal transformada, y la entropía espectral, que mide la complejidad e imprevisibilidad del contenido frecuencial. Ambas métricas han demostrado ser discriminativas al diferenciar ritmos cardíacos regulares de señales afectadas por arritmias complejas, debido a los patrones más irregulares y dispersos que estas últimas presentan.

3) *Coefficientes Cepstrales en Frecuencia Mel MFCC*: esta se calcula mediante la librería (python\_speech\_features mfcc) con siguiente proceso:

- **Segmentación**: División de la señal ECG en ventanas de **200 ms** con solapamiento del 50%.
- **Transformada de Fourier**: Aplicación de FFT a cada segmento:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j2\pi kn/N}$$

### C. Extracción MFCC

- 1) **Banco de filtros Mel**: 20 filtros triangulares espaciados según la escala Mel:

$$f_{\text{Mel}} = 2595 \log_{10} \left( 1 + \frac{f}{700} \right)$$

- 2) **Log-energías**: Conversión de energías espectrales a escala logarítmica:

$$E_m = \log \left( \sum_{k=0}^{N-1} |X[k]|^2 \cdot H_m[k] \right), \quad m = 1, \dots, 20$$

donde  $H_m[k]$  es la respuesta del  $m$ -ésimo filtro Mel.

- 3) **DCT tipo II**: Aplicación para decorrelacionar las bandas Mel:

$$C[n] = \sum_{m=1}^{20} E_m \cdot \cos \left( \frac{\pi n(m-0.5)}{20} \right), \quad n = 0, \dots, 9$$

Se conservan solo los primeros numcep=9 coeficientes.

Durante todo el procedimiento se implemento el algoritmo 10 [4] para realizar una extracción centrada en cada latido individual, antes de aplicar los metodos, se aplicó una normalización por z-score a cada señal ECG, tal como se implementa en la línea `ecg = (ecg - np.mean(ecg)) / np.std(ecg)`. Este procedimiento transformó cada señal para tener media cero y desviación estándar uno, eliminando diferencias de escala causadas por factores como el voltaje de adquisición, el tipo de equipo o el nivel de ruido presente. Esta estandarización permitió que los coeficientes MFCC, basados en energía espectral, fueran más consistentes y comparables entre distintos pacientes, al evitar que el nivel absoluto de la señal influya en el resultado final.

En cuanto a la configuración temporal, se emplearon ventanas de 200 milisegundos, desplazadas cada 100 ms, para la segmentación de la señal ECG. Esta elección difiere de los parámetros utilizados en aplicaciones de voz, donde las ventanas típicamente oscilan entre 20–30 ms [16]; [17]. La diferencia se justifica por la naturaleza fisiológica del ECG: un ciclo cardíaco completo tiene una duración de 600–1000 ms, con componentes como el complejo QRS (80–120 ms) y la onda T (hasta 200 ms) [20]. Utilizar ventanas de 200 ms permite capturar estos elementos clínicamente relevantes sin fragmentarlos, preservando la morfología y mejorando la relación señal-ruido. Esta decisión está respaldada por investigaciones previas que emplean ventanas entre 150–300 ms para el análisis espectral de señales ECG [13]; [20].

La extracción de coeficientes MFCC se realizó utilizando la función `mfcc()` de la librería `python_speech_features`. Primero, se calcula el espectro de cada ventana mediante la FFT y se aplica un banco de filtros Mel (20 bandas), simulando la percepción auditiva adaptada a la dinámica del ECG, luego, se aplica una Transformada Discreta del Coseno (DCT tipo II) sobre el vector de log-energías, reduciendo la redundancia y compactando la información.

Finalmente, se conservan únicamente los primeros 9 coeficientes MFCC, resultando en una matriz de dimensión (n\_frames, 9) donde cada fila representa una ventana temporal de la señal.

La elección de emplear solo 9 coeficientes se basó en tres criterios fundamentales. Primero, a diferencia del habla humana, que requiere más coeficientes para capturar su complejidad espectral, el ECG es una señal más lenta y periódica, con la mayoría de su energía concentrada en frecuencias bajas y medias. Segundo, coeficientes de orden superior (10–13) tienden a representar ruido o artefactos musculares más que información fisiológica útil. Tercero, reducir la dimensionalidad del vector de características mejora la eficiencia computacional y reduce el riesgo de sobreajuste en modelos de clasificación. Esta estrategia ha sido validada en estudios donde los primeros coeficientes MFCC contienen la mayor capacidad discriminativa en tareas de análisis cardíaco [15].

Sobre la matriz resultante de MFCC se calcularon diversas métricas estadísticas por canal, La media y la desviación estándar de los MFCC capturan la tendencia central y la dispersión de la energía espectral de la señal, reflejando variaciones en la morfología de los latidos cardíacos asociados a diferentes tipos de arritmias [19]. La asimetría (skewness) y la curtosis proporcionan información sobre la simetría y la concentración de la distribución espectral, permitiendo identificar patrones anómalos característicos de ciertas arritmias [20]. Además, la energía total de los MFCC indica la potencia global de la señal, mientras que la entropía mide la complejidad o el desorden espectral, siendo útil para detectar irregularidades en el ritmo cardíaco [21]. Estas características, combinadas, ofrecen una representación robusta de las señales ECG, facilitando la discriminación efectiva entre ritmos cardíacos normales y patológicos [19] [15].

#### D. Comparación de Características entre grupos

A partir de los datos obtenidos con DFT, DCT y MFCC, se seleccionaron dos características por técnica, eligiendo aquellas que fueran representativas y comparables entre sí:

- Para DFT (Transformada Discreta de Fourier): Se eligió la frecuencia pico, porque representa la frecuencia dominante del espectro, la cual puede variar según el ritmo cardíaco (por ejemplo, ritmos rápidos tienen frecuencias dominantes más altas). También se seleccionó la energía total, ya que indica cuánta actividad o intensidad contiene la señal en el dominio de la frecuencia. Estas dos variables son útiles para diferenciar entre ritmos más activos (como taquicardias) y ritmos más lentos o irregulares (como bradicardias o AFIB).
- Para DCT (Transformada Discreta del Coseno): Se utilizó el promedio de los coeficientes (`dct_mean`), que refleja cómo se distribuye globalmente la energía a lo largo de la señal transformada, y la desviación estándar (`dct_std`), que mide la variabilidad o dispersión de esa energía. Estas características fueron elegidas porque la DCT tiende a concentrar la información útil en los primeros coeficientes, lo que facilita capturar diferencias sutiles en la morfología general de la señal ECG.
- Para MFCC (Coeficientes Cepstrales en las Frecuencias de Mel): Se seleccionó la energía (`mfcc_energy`), como medida de intensidad de la señal en este dominio, y la entropía (`mfcc_entropy`), como medida del nivel de desorden o complejidad de la señal. Estas variables permiten captar patrones más globales y complejos que son útiles para distinguir entre señales regulares (como el ritmo sinusal) e irregulares o caóticas (como la fibrilación auricular).

Para cada técnica (DFT, DCT y MFCC), se visualizaron las características seleccionadas mediante gráficos de cajas, comparando todos los grupos de pacientes según su tipo de ritmo cardíaco. Estas visualizaciones permitieron observar de forma preliminar cómo se distribuían las variables en cada grupo, identificar posibles diferencias entre ritmos, y detectar valores extremos o variabilidad relevante. A partir de la visualización del gráfico de caja, se decidió comparar:

- SR vs AFIB, por representar un ritmo normal frente a una arritmia clínicamente importante.
- SR vs SB, por corresponder ambos a ritmos sinusales, pero con diferencias fisiológicas en la frecuencia cardíaca.
- SB vs ST, como extremos de un mismo origen sinusal (bradicardia vs taquicardia).
- ST vs SVT, por ser ambos ritmos rápidos pero de distinto origen y complejidad eléctrica.

Luego, se evaluó la normalidad de los datos con la prueba de Shapiro-Wilk, y al encontrarse que las variables no seguían una distribución normal, se aplicó la prueba de Mann-Whitney U para determinar la significancia de las diferencias observadas.

Finalmente, para complementar los resultados obtenidos en

las pruebas estadísticas y facilitar la interpretación visual, se realizaron gráficos de violín para cada comparación. Estos gráficos permitieron observar la forma completa de las distribuciones, la concentración de los datos, y reforzaron la comprensión de los hallazgos estadísticos.

#### IV. ANÁLISIS Y RESULTADOS

A continuación, se presentan los resultados obtenidos a partir del análisis de señales ECG utilizando tres métodos diferentes de transformación: la Transformada Discreta de Fourier (DFT), la Transformada Discreta del Coseno (DCT) y los coeficientes cepstrales en la escala mel (MFCC). Para cada uno, se seleccionaron las características más representativas de la señal, y se muestran gráficos de caja que permiten visualizar cómo varían estas características entre los diferentes tipos de ritmo cardíaco registrados en la base de datos.

##### A. Análisis de Características obtenidas con DFT




Fig. 1: Comparación del Gráfico de Cajas de dos características obtenidas con DFT.

La Figura 1 muestra cómo varía la frecuencia dominante de la señal ECG entre los distintos ritmos, en donde ritmos como ST (taquicardia sinusal) y SVT (taquicardia supraventricular) presentan frecuencias pico más altas, lo cual es consistente con su naturaleza rápida. Por el contrario, ritmos como SB (bradicardia sinusal) y SA (arritmia sinusal) muestran frecuencias pico más bajas y concentradas. AFIB (fibrilación auricular) también presenta una mayor dispersión, y alcanza valores más altos, lo que sugiere una mayor variabilidad en la frecuencia dominante. Esta variabilidad se asocia con la actividad eléctrica desorganizada típica de la fibrilación auricular, que genera un espectro más amplio y menos predecible [23].

En cuanto a la energía total, también ritmos como SVT y ST tienden a tener valores más altos, con presencia de algunos valores muy por encima. Esto puede deberse a la mayor cantidad de eventos eléctricos por unidad de tiempo. AFIB y SB muestran energías más bajas y menos dispersas, lo que podría reflejar una conducción menos eficiente o más desorganizada en la señal [23].

Con el fin de evaluar si las características espectrales extraídas mediante la Transformada Discreta de Fourier (DFT)

permiten diferenciar entre distintos tipos de ritmo cardíaco, se realizaron comparaciones estadísticas utilizando la prueba de normalidad de Shapiro–Wilk. Al indicar que ninguna variable sigue una distribución normal, se procedió a aplicar la prueba no paramétrica de Mann–Whitney U.

Además, se decidió comparar solamente algunos de los grupos para realizar las pruebas estadísticas. Una de las comparaciones se realizó entre el ritmo sinusal normal (SR), que refleja un patrón eléctrico regular y saludable del corazón, y la fibrilación auricular (AFIB), una arritmia común asociada a mayor riesgo de accidente cerebrovascular e insuficiencia cardíaca [23]. También se compararon pacientes con SR y bradicardia sinusal (SB), ya que, aunque ambos comparten origen en el nodo sinusal, presentan frecuencias cardíacas diferentes que pueden reflejarse en sus características espectrales. De igual manera, se incluyó la comparación entre taquicardia sinusal (ST) y taquicardia supraventricular (SVT), dado que ambos ritmos son rápidos pero difieren en su origen: ST es una respuesta fisiológica y transitoria, mientras que SVT (taquicardia supraventricular) es un ritmo rápido que, a diferencia de la taquicardia sinusal (ST), no es una respuesta normal del cuerpo, sino que suele deberse a una señal eléctrica que se queda dando vueltas dentro del corazón. Por último, se comparó SB con ST, ya que representan los dos extremos de funcionamiento del nodo sinusal: una frecuencia muy baja frente a una acelerada, lo cual puede impactar significativamente en la frecuencia dominante y en la energía del espectro de la señal ECG Tabla I.

Comparación de ritmos	¿Normalidad?	Frecuencia pico (p)	¿Significativa?	Energía total (p)	¿Significativa?
SR vs AFIB	No	$9.21 \times 10^{-1}$	No	$7.73 \times 10^{-1}$	No
SR vs SB	No	$7.98 \times 10^{-87}$	Sí	$1.16 \times 10^{-16}$	Sí
ST vs SVT	No	$9.19 \times 10^{-6}$	Sí	$2.04 \times 10^{-22}$	Sí
SB vs ST	No	$8.29 \times 10^{-229}$	Sí	$1.92 \times 10^{-75}$	Sí

TABLE I: Resumen de pruebas de normalidad y pruebas estadísticas Mann–Whitney U para características DFT

Los resultados de las pruebas estadísticas muestran que la frecuencia pico y la energía total permiten distinguir con claridad entre la mayoría de los ritmos cardíacos comparados, excepto entre ritmo sinusal normal (SR) y fibrilación auricular (AFIB), donde no se encontraron diferencias estadísticamente significativas. Esto puede deberse a que en algunos registros de AFIB la señal conserva una frecuencia dominante similar al ritmo sinusal, a pesar de su irregularidad interna. En contraste, las comparaciones entre SR y SB, ST y SVT, y SB y ST mostraron diferencias significativas tanto en la frecuencia pico como en la energía, lo que confirma que estas características espectrales capturan variaciones importantes entre ritmos con distinta frecuencia cardíaca o con diferente origen eléctrico. Además, en todos los casos evaluados, se comprobó que los datos no seguían una distribución normal, por lo que se utilizó la prueba no paramétrica de Mann–Whitney U para asegurar la validez de los resultados.

Para complementar los análisis estadísticos, se construyeron gráficos de violín Figura 2 que permiten observar no solo los valores centrales y la dispersión de las características

espectrales, sino también la forma completa de la distribución.

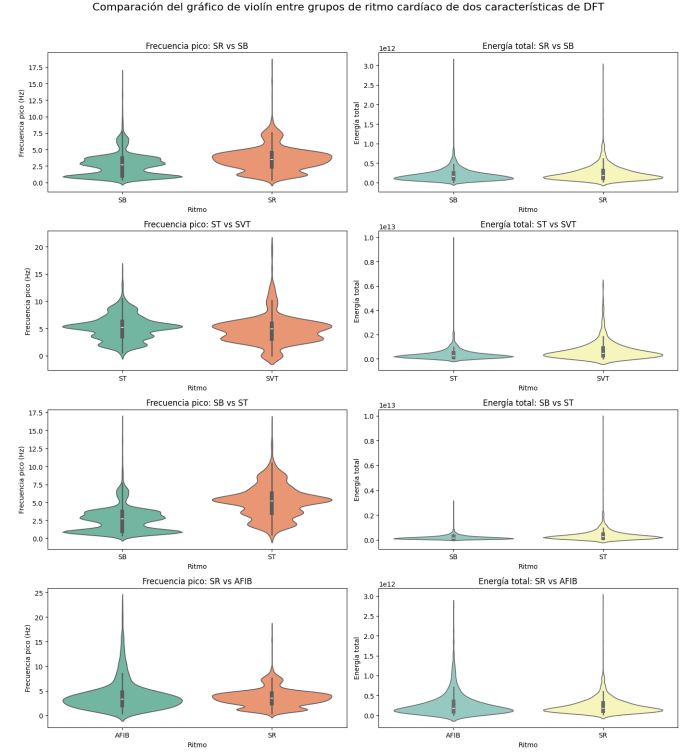


Fig. 2: Comparación del Gráfico de Violín de dos características obtenidas con DFT entre grupos de pacientes.

En la Figura 2 se puede observar cómo varía la frecuencia pico y la energía total entre grupos. Por ejemplo, en la comparación entre SB y ST, las distribuciones son claramente distintas en ambas características: ST presenta valores más altos y dispersos, lo que coincide con los p-valores extremadamente bajos ( $p < 10^{-22}$ ), indicando una diferencia significativa. De forma similar, entre SR y AFIB, se observa una mayor dispersión en AFIB, especialmente en la frecuencia pico, lo cual concuerda con su naturaleza irregular y con la ausencia de significancia estadística solo en energía total, tal como lo señala la tabla. Finalmente, en ST vs SVT, aunque ambos ritmos son rápidos, las diferencias en las formas de los violines y en la amplitud de la energía también se evidencian diferencias en ambas variables, lo que también fue respaldado por las pruebas estadísticas que indican significancia ( $p < 0.05$ ).

## B. Análisis de Características obtenidas con DCT

A continuación se presenta un gráfico de caja correspondiente a dos características calculadas con la Transformada Discreta del Coseno (DCT): el promedio de los coeficientes (dct\_mean) y la desviación estándar de los coeficientes (dct\_std). Estas características permiten observar cómo varía la energía y la complejidad de la señal ECG entre distintos grupos de ritmo cardíaco.






Fig. 3: Comparación del Gráfico de Cajas de dos características obtenidas con DCT.

La Figura 3 en el gráfico del promedio de los coeficientes ( $dct\_mean$ ) se aprecia que ritmos como SB (bradicardia sinusal) y SR (ritmo sinusal) presentan valores más altos en promedio, lo cual puede deberse a que su señal es más estable, y por eso gran parte de su energía se concentra en las primeras partes del espectro [25]. En cambio, ritmos como AFIB muestran valores promedio más bajos y una mayor dispersión, lo que sugiere que su energía está más repartida y su señal es menos organizada, como ocurre en ritmos irregulares. Por otro lado, al observar la desviación estándar ( $dct\_std$ ), que nos indica qué tanto varían los datos, vemos que ritmos como AFIB y SB presentan mayor variabilidad, lo que quiere decir que son señales menos predecibles.

Con el fin de evaluar si las características extraídas mediante la Transformada Discreta del Coseno (DCT) permiten diferenciar entre distintos tipos de ritmo cardíaco, se realizaron comparaciones estadísticas utilizando la prueba de normalidad de Shapiro–Wilk. Al indicar que ninguna variable sigue una distribución normal, se procedió a aplicar la prueba no paramétrica de Mann–Whitney U.

Comparación de ritmos	¿Distribución normal?	$dct\_mean$ (p-valor)	¿Significativa?	$dct\_std$ (p-valor)	¿Significativa?
SR vs AFIB	No	$5.75 \times 10^{-38}$	Si	$8.59 \times 10^{-12}$	Si
SR vs SB	No	$2.75 \times 10^{-224}$	Si	$1.45 \times 10^{-112}$	Si
ST vs SVT	No	$4.95 \times 10^{-187}$	Si	$1.41 \times 10^{-11}$	Si
SB vs ST	No	$< 1 \times 10^{-300}$	Si	$9.36 \times 10^{-297}$	Si

TABLE II: Resumen de pruebas de normalidad y pruebas estadísticas Mann–Whitney U para características DCT

La Tabla II muestra los resultados de las pruebas estadísticas aplicadas a las características extraídas mediante la Transformada Discreta del Coseno (DCT): el promedio ( $dct\_mean$ ) y la desviación estándar ( $dct\_std$ ) de los coeficientes. En todos los casos analizados, se comprobó previamente que los datos no siguen una distribución normal ( $p < 0.05$  en la prueba de Shapiro–Wilk), por lo que se utilizó la prueba no paramétrica de Mann–Whitney U. Los resultados muestran que hay diferencias estadísticamente significativas entre todos los pares de grupos comparados, tanto en el promedio como en la dispersión de los coeficientes DCT. Esto sugiere que estas características capturan de forma efectiva las diferencias espectrales entre ritmos normales y alterados, reflejando no solo la intensidad general de la señal (a través del promedio),

sino también su complejidad y variabilidad (a través de la desviación estándar).

Con el fin de complementar los resultados estadísticos obtenidos mediante la prueba de Mann–Whitney U, se construyeron gráficos de violín que permiten visualizar en detalle la distribución de las características  $dct\_mean$  y  $dct\_std$  entre los diferentes ritmos cardíacos.

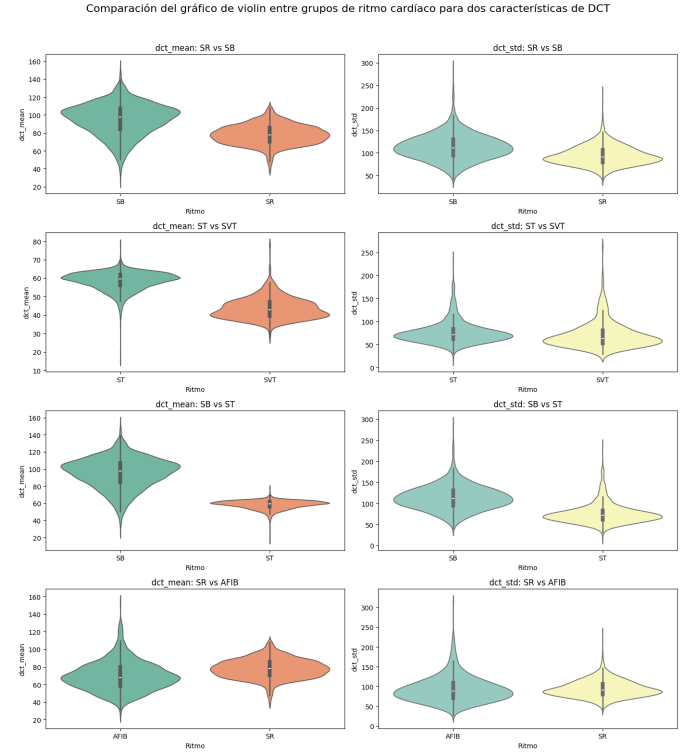


Fig. 4: Comparación del Gráfico de Violín características obtenidas con DCT entre grupos.

En la Figura 4 se observa que en todas las comparaciones, las distribuciones entre los grupos difieren, lo cual coincide con los resultados estadísticamente significativos obtenidos previamente. Por ejemplo, en la comparación entre SB y ST, tanto el valor promedio ( $dct\_mean$ ) como la variabilidad ( $dct\_std$ ) de los coeficientes DCT presentan diferencias en su forma y amplitud, reflejando la diferencia fisiológica entre un ritmo lento y uno acelerado. En el caso de SR vs AFIB, AFIB muestra una distribución más dispersa, lo cual es coherente con la irregularidad típica de este tipo de arritmia. Por otro lado, en la comparación entre ST y SVT, a pesar de tratarse de ritmos rápidos, se evidencian diferencias en ambas características, posiblemente debido a que SVT suele involucrar patrones eléctricos más complejos o patológicos [9].

### C. Análisis de Características obtenidas con MFCC

A continuación se presenta un gráfico de caja correspondiente a dos características calculadas con los coeficientes cepstrales de frecuencia Mel (MFCC): la energía total contenida en los coeficientes MFCC ( $mfcc\_energy$ ) y la entropía de

la señal en el dominio MFCC (mfcc\_entropy). Estas características permiten capturar aspectos globales de la señal ECG relacionados con su intensidad y su complejidad estructural.




Fig. 5: Comparación del Gráfico de Cajas de dos características obtenidas con DCT.

En la Figura 5 en el gráfico de la energía total, podemos ver que ritmos como AFIB, AF, SVT y AT tienden a tener valores más altos. Esto quiere decir que estas señales contienen más "actividad" o intensidad, lo cual tiene sentido porque son ritmos que suelen ser rápidos o irregulares. Por el contrario, ritmos como SB y SA, que son más lentos o estables, muestran menos energía [10].

En el análisis de la entropía en el dominio MFCC (mfcc\_entropy), que todos los grupos presentan valores negativos y que AFIB es muy disperso en comparación con otros ritmos. Esta mayor variabilidad y amplitud hacia valores extremos sugiere que la señal ECG en pacientes con fibrilación auricular es más irregular y desorganizada, lo cual es coherente con el comportamiento clínico conocido de esta arritmia. En contraste, ritmos como SR o SB muestran distribuciones más concentradas, lo que refleja una señal más estable. Estos resultados refuerzan la utilidad de la entropía como indicador de la complejidad de la señal ECG [8].

Con el fin de evaluar si las características extraídas mediante MFCC, permiten diferenciar entre distintos tipos de ritmo cardíaco, se realizaron comparaciones estadísticas utilizando la prueba de normalidad de Shapiro–Wilk. Al indicar que ninguna variable sigue una distribución normal, se procedió a aplicar la prueba no paramétrica de Mann–Whitney U.

Comparación de ritmos	¿Normalidad?	mfcc_energy (p)	¿Significativa?	mfcc_entropy (p)	¿Significativa?
SR vs AFIB	No	$7.34 \times 10^{-54}$	Sí	$4.07 \times 10^{-57}$	Sí
SR vs SB	No	$9.99 \times 10^{-221}$	Sí	$7.08 \times 10^{-153}$	Sí
ST vs SVT	No	$8.61 \times 10^{-52}$	Sí	$2.64 \times 10^{-39}$	Sí
SB vs ST	No	0	Sí	0	Sí

TABLE III: Resumen de pruebas de normalidad y pruebas estadísticas Mann–Whitney U para características MFCC

Los resultados presentados en la Tabla III muestran que las características mfcc\_energy y mfcc\_entropy permiten diferenciar de manera estadísticamente significativa entre todos los pares de ritmos analizados. En primer lugar, la prueba de Shapiro–Wilk confirmó que en todos los casos los datos no siguen una distribución normal ( $p < 0.05$ ), por lo que se aplicó

la prueba no paramétrica de Mann–Whitney U. Esta prueba arrojó p-valores extremadamente bajos (algunos menores a  $10^{-200}$ ), lo que indica que tanto la energía como la entropía en el dominio MFCC capturan diferencias importantes entre ritmos normales y patológicos. Por ejemplo, ritmos como AFIB y SVT, que son más irregulares o intensos, presentan patrones significativamente distintos en estas métricas comparados con ritmos como SR o SB, que son más regulares. Esto refuerza el valor de estas características como herramientas discriminativas en el análisis de señales ECG.

A continuación, se presenta un gráfico de violín que ilustra visualmente las diferencias identificadas en las pruebas estadísticas. Estas representaciones permiten observar con mayor claridad cómo varían las distribuciones de energía y entropía entre los distintos ritmos cardíacos, respaldando las diferencias significativas detectadas por la prueba de Mann–Whitney U.

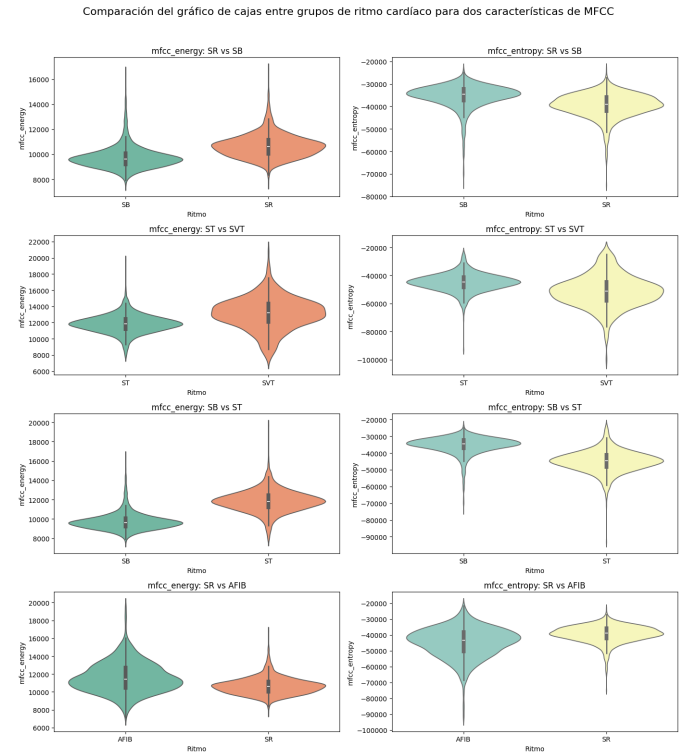


Fig. 6: Comparación del Gráfico de Violín de dos características obtenidas con MFCC.

En la Figura 6 se puede observar que en todas las comparaciones de grupos, las distribuciones de las características mfcc\_energy y mfcc\_entropy muestran diferencias claras, lo cual concuerda con los resultados estadísticos obtenidos previamente. Por ejemplo, en la comparación entre SB y ST, se nota una separación visible tanto en los niveles de energía como en la dispersión de la entropía, lo que refleja el contraste entre un ritmo más lento y uno acelerado. En el caso de SR vs AFIB, la distribución de AFIB es mucho más extendida y dispersa, algo que se espera por la naturaleza irregular y caótica de esta arritmia. Finalmente, en la comparación entre ST y SVT, a



pesar de que ambos ritmos son rápidos, se observan diferencias marcadas en las formas de las distribuciones, lo que podría relacionarse con la mayor complejidad eléctrica presente en los episodios de SVT [8].

#### D. ¿Qué característica discrimina mejor entre los grupos?

Al analizar los resultados obtenidos con las tres técnicas de extracción de características (DFT, DCT y MFCC), se puede observar que las características de DCT y MFCC muestran buena capacidad de discriminación entre los diferentes grupos de ritmos cardíacos, en comparación con las de DFT.

Sin embargo, los resultados obtenidos indican que entre las técnicas de DCT y MFCC, las características obtenidas con DCT muestran mejor discriminación entre los grupos que las características de MFCC, ya que estas tienen un p-valor mucho más bajo. Por otro lado, entre la desviación estándar de los coeficientes (*dct\_std*) y el promedio de los coeficientes (*dct\_mean*), *dct\_std* es la característica que mejor discrimina entre los grupos analizados.

Las pruebas de Mann–Whitney U mostraron que *dct\_mean* posee diferencias estadísticamente significativas entre los grupos analizados, con valores de p extremadamente bajos (mucho más bajos que *dct\_std*). Al tener un p valor tan bajo, podemos decir que sí hay diferencias estadísticamente significativas entre los tipos de ritmos cardíacos. Por otro lado, en los gráficos de violín, las distribuciones de *dct\_mean* entre los distintos grupos de ritmos cardíacos fueron claramente diferenciables, especialmente entre ritmos opuestos como la bradicardia sinusal (SB) y la taquicardia sinusal (ST), lo que refuerza de manera visual que esta característica es la mejor discrimina entre los grupos.

Además, al buscar en la literatura, encontramos estudios donde han mostrado que la Transformada Discreta del Coseno (DCT) es una herramienta muy útil para analizar señales del corazón. Por ejemplo, en un estudio se logró clasificar diferentes tipos de arritmias con una precisión del 98.8% usando características extraídas con la DCT [7], lo que significa que la DCT es buena para detectar diferencias en la forma de las señales eléctricas del corazón, tanto en ritmos normales como en aquellos con problemas. En nuestro caso, el promedio de los coeficientes DCT (*dct\_mean*) permitió identificar claramente diferencias entre los grupos de pacientes.

#### V. DISCUSIÓN

Este estudio permitió explorar cómo diferentes características espectrales pueden ayudar a distinguir entre distintos tipos de ritmos cardíacos a partir de señales ECG. En general, los resultados mostraron que las transformaciones DCT y MFCC ofrecieron una mejor discriminación entre los grupos que la DFT. Sin embargo, la característica *dct\_mean* (el promedio de los coeficientes del coseno) logró los valores de p más bajos en las pruebas estadísticas, lo que indica que fue la más efectiva para detectar diferencias entre los diferentes

tipos ritmos cardíacos. Además, en los gráficos de violín se pudo ver claramente cómo las distribuciones de *dct\_mean* eran distintas entre los grupos, lo que refuerza de manera visual que *dct\_mean* discrimina mejor.

Adicionalmente, este estudio resalta la importancia de adaptar los parámetros de segmentación y extracción al tipo de señal analizada. La elección de ventanas de 500 ms para DCT centradas en los picos R, y de 200 ms con desplazamientos de 100 ms para MFCC, no solo se justificó fisiológicamente, sino que demostró ser efectiva para capturar la morfología completa de cada latido. Otro elemento como la autocorrelación previa a la DCT (Algoritmo 9) potenció la robustez de las características extraídas al reforzar la repetitividad de los patrones cardíacos, mientras que el uso de z-score antes de MFCC (Algoritmo 10) permitió mitigar el efecto de variaciones en escala entre registros, mejorando la comparabilidad entre pacientes.

Por otra parte, aunque la DFT proporcionó métricas clásicas como frecuencia pico y energía total, que resultaron útiles para distinguir entre ritmos con diferencias marcadas en la frecuencia cardíaca (como SB vs ST), su capacidad de discriminación fue limitada frente a ritmos irregulares como AFIB, probablemente debido a la pérdida de información temporal en su espectro global. En contraste, DCT y MFCC, al preservar la estructura latido a latido, capturaron mejor la complejidad morfológica e irregularidad de los ritmos patológicos.

Es destacable que las métricas de entropía y energía aparecieron consistentemente entre las más discriminativas en todas las transformadas, reflejando que la combinación de intensidad y complejidad espectral es clave para caracterizar arritmias. En particular, *mfcc\_entropy* mostró una dispersión notable en pacientes con AFIB, lo cual coincide con la naturaleza altamente irregular de esta arritmia. No obstante, *dct\_mean* sobresalió por sus valores de p extremadamente bajos y por su capacidad para diferenciar incluso entre ritmos similares en frecuencia pero distintos en origen, como ST y SVT. Este hallazgo concuerda con estudios previos que validan el uso de DCT como herramienta para análisis espectral fino de señales ECG [7], [11].

#### VI. CONCLUSIONES

Este estudio permitió comparar el rendimiento de tres técnicas de análisis espectral —DFT, DCT y MFCC— para extraer características de señales ECG con el objetivo de diferenciar entre distintos tipos de ritmos cardíacos. A partir de las pruebas estadísticas y los gráficos generados, se concluye que la DCT fue la técnica que mostró mejores resultados generales en cuanto a capacidad discriminativa.

En particular, la característica *dct\_mean* (promedio de los coeficientes del coseno) presentó los valores de p más bajos en todas las comparaciones realizadas, lo que indica una diferencia estadísticamente significativa entre los grupos. Esta conclusión la pudimos confirmar tanto por las pruebas estadísticas de Mann–Whitney U, donde se obtuvieron valores de p extremadamente bajos, así como también visualmente

mediante los gráficos de violín, donde las distribuciones fueron claramente distintas entre ritmos

Por tanto, vemos que este trabajo proporciona evidencia de que la DCT y MFCC pueden ser herramientas útiles para el preprocesamiento de señales ECG en sistemas automáticos de diagnóstico. Estas técnicas podrían aplicarse fácilmente en herramientas que ayuden al diagnóstico médico, como en programas que analizan señales ECG de forma automática o en dispositivos portátiles que monitorean el ritmo del corazón. Gracias a su capacidad para detectar diferencias entre ritmos normales y anormales, pueden ser muy útiles para identificar arritmias a tiempo y así mejorar el seguimiento y cuidado de los pacientes.

## REFERENCES

- [1] Organización Mundial de la Salud, “Enfermedades cardiovasculares (ECV),” OMS, 2023. [En línea]. Disponible en: <https://www.who.int/es/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>
- [2] The Merck Manual, “Electrocardiografía,” Manual MSD, [En línea]. Disponible en: <https://www.merckmanuals.com/es-us/hogar/trastornos-del-coraz%C3%B3n-y-los-vasos-sangu%C3%ADneos/diagn%C3%B3stico-de-las-enfermedades-cardiovasculares/electrocardiograf%C3%ADa>
- [3] J. Pathoumvanh et al., “Electrocardiogram rhythm classification using deep learning and spectral analysis,” *Sci. Rep.*, vol. 14, art. 759, 2024. [En línea]. Disponible en: <https://www.nature.com/articles/s41598-024-59311-0>
- [4] S. A. Lone et al., “ECG signal feature extraction trends in methods and applications,” *BioMedical Engineering OnLine*, vol. 22, no. 1, 2023. [En línea]. Disponible en: <https://biomedical-engineering-online.biomedcentral.com/articles/10.1186/s12938-023-01075-1>
- [5] “The Dummy’s Guide to MFCC,” Medium, [En línea]. Disponible en: <https://medium.com/prathena/the-dummys-guide-to-mfcc-aceab2450fd>
- [6] N. Sharma et al., “A review of signal processing techniques for ECG analysis,” ResearchGate, 2015. [En línea]. Disponible en: <https://www.researchgate.net/publication/277553387>
- [7] H.-e. Kim, S.-g. Ha, H. Rehman, y H.-k. Yoo, “ECG Identification Based on Non-Fiducial Feature Extraction Using Window Removal Method,” *Applied Sciences*, vol. 7, no. 11, art. 1205, 2017. [Online]. Disponible en: <https://www.mdpi.com/2076-3417/7/11/1205>
- [8] G. B. Moody and R. G. Mark, “The impact of the MIT-BIH arrhythmia database,” *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, May–June 2001. doi: 10.1109/51.932724
- [9] D. P. Zipes, P. Libby, R. O. Bonow, D. L. Mann, and G. F. Tomaselli, *Braunwald’s Heart Disease: A Textbook of Cardiovascular Medicine*, 11th ed. Philadelphia, PA, USA: Elsevier, 2018.
- [10] G. B. Moody and R. G. Mark, “The impact of the MIT-BIH arrhythmia database,” *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, May–June 2001. doi: 10.1109/51.932724
- [11] A. Chia et al., “Arrhythmia Classification Based on Combined Chaotic and Statistical Features of ECG Signals,” *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 12, no. 1, pp. 127–136, Oct. 2018. [En línea]. Disponible en: <https://ijeeecs.iaescore.com/index.php/IJEECS/article/viewFile/11484/9311>
- [12] M. Mohebbi y H. Ghassemian, “Detection of Atrial Fibrillation Episodes Using SVM,” *IEEE Computers in Biology and Medicine*, vol. 42, no. 1, pp. 66–72, Jan. 2012. [En línea]. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/19162622/>
- [13] J. P. Martínez et al., “A Wavelet-Based ECG Delineator: Evaluation on Standard Databases,” *IEEE Transactions on Biomedical Engineering*, vol. 51, no. 4, pp. 570–581, 2004. [En línea]. Disponible en: <https://dicc.unizar.es/laguna/personal/publicaciones/wavedet/bme04.pdf>
- [14] G. D. Clifford, F. Azuaje y P. E. McSharry, *Advanced Methods and Tools for ECG Data Analysis*. Artech House, 2006. [En línea]. Disponible en: <https://www.mit.edu/~gari/ecgbook/ch6.pdf>
- [15] M. Atibi, M. F. M. Salleh y M. A. M. Ali, “ECG Signals Classification Using MFCC Coefficients and ANN Classifier,” 2016. [En línea]. Disponible en: [https://www.researchgate.net/publication/305649823\\_ECG\\_signals\\_classification\\_using\\_mfcc\\_coefficients\\_and ANN\\_classifier](https://www.researchgate.net/publication/305649823_ECG_signals_classification_using_mfcc_coefficients_and ANN_classifier)
- [16] A. Goyal, “MFCC Technique for Speech Recognition,” *Analytics Vidhya*, Jun. 2021. [En línea]. Disponible en: <https://www.analyticsvidhya.com/blog/2021/06/mfcc-technique-for-speech-recognition>
- [17] MathWorks, “Speaker Identification Using Pitch and MFCC,” [En línea]. Disponible en: <https://es.mathworks.com/help/audio/ug/speaker-identification-using-pitch-and-mfcc.html>
- [18] A. R. Edla et al., “Classification of Heart Sounds Using Motif-Based Spectral Features and Temporal Features,” *Journal of Medical Systems*, vol. 43, no. 5, 2019. [En línea]. Disponible en: <https://link.springer.com/article/10.1007/s10916-019-1286-5>
- [19] N. C. Krishnan y D. J. Cook, “ECG Signal Classification Using DWT, MFCC and SVM Classifier,” 2023. [En línea]. Disponible en: [https://www.researchgate.net/publication/369462681\\_ECG\\_signal\\_classification\\_using\\_dwt\\_mfcc\\_and\\_svm\\_classifier](https://www.researchgate.net/publication/369462681_ECG_signal_classification_using_dwt_mfcc_and_svm_classifier)
- [20] S. Satija, S. Ramkumar y M. S. Manikandan, “Automated ECG Noise Detection and Classification System Based on Skewness and Kurtosis,” en *Proc. Computers in Biology and Medicine*, vol. 87, 2017, pp. 271–279. [En línea]. Disponible en: [https://www.researchgate.net/figure/Skewness-kurtosis-distribution-for-different-quality-ECG-signals\\_fig4\\_325761954](https://www.researchgate.net/figure/Skewness-kurtosis-distribution-for-different-quality-ECG-signals_fig4_325761954)
- [21] G. Tzanetakis y P. Cook, “Musical Genre Classification of Audio Signals,” *IEEE Transactions on Speech and Audio Processing*, vol. 10, no. 5, pp. 293–302, Jul. 2002. [En línea]. Disponible en: <https://arxiv.org/abs/0810.1404>
- [22] S. A. Lone et al., “ECG Signal Feature Extraction Trends in Methods and Applications,” *BioMedical Engineering OnLine*, vol. 22, no. 1, 2023. [En línea]. Disponible en: <https://biomedical-engineering-online.biomedcentral.com/articles/10.1186/s12938-023-01075-1>
- [23] A. M. Khan, R. Hussain, M. A. Khan, A. Rehman, and K. Muhammad, “A novel method for the classification of tumors in brain MRI using a hybrid feature extraction technique,” *Comput. Biol. Med.*, vol. 67, pp. 104–113, Mar. 2015, doi: 10.1016/j.compbiomed.2015.01.006.
- [24] F. Shaffer and J. P. Ginsberg, “An overview of heart rate variability metrics and norms,” *Front. Public Health*, vol. 5, p. 258, 2017, doi: 10.3389/fpubh.2017.00258.
- [25] F. Lombardi, “Clinical implications of present physiological understanding of HRV components,” *Cardiovasc. Res.*, vol. 70, no. 2, pp. 211–217, 2006, doi: 10.1016/j.cardiores.2006.05.011.
- [26] R. V. Rao, V. J. Savsani, and D. P. Vakharia, “Teaching–learning-based optimization: A novel method for constrained mechanical design optimization problems,” *Expert Systems with Applications*, vol. 38, no. 3, pp. 4247–4255, Mar. 2011. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0957417406000844>
- [27] W. Zong, G. B. Moody, and D. Jiang, “A robust open-source algorithm to detect onset and duration of QRS complexes,” in *Proc. Comput. Cardiol.*, vol. 30, pp. 737–740, 2003, doi: 10.1109/CIC.2003.1291329.
- [28] G. S. Wagner and D. G. Strauss, *Marriott’s Practical Electrocardiography*, 11th ed. Philadelphia: Lippincott Williams & Wilkins, 2009.
- [29] A. L. Goldberger, *Clinical Electrocardiography: A Simplified Approach*, 7th ed. St. Louis: Mosby, 2000.
- [30] F. Shaffer and J. P. Ginsberg, “An overview of heart rate variability metrics and norms,” *Front. Public Health*, vol. 5, p. 258, 2017, doi: 10.3389/fpubh.2017.00258.
- [31] J. F. Thayer, F. Åhs, M. Fredrikson, J. J. Sollers, and T. D. Wager, “A meta-analysis of heart rate variability and neuroimaging studies: Implications for heart rate variability as a marker of stress and health,” *Neurosci. Biobehav. Rev.*, vol. 33, no. 2, pp. 81–88, 2010, doi: 10.1016/j.neubiorev.2009.12.002.
- [32] D. Makowski, C. Pham, D. Lau, J. Brammer, T. Lespinasse, F. Pham, and R. T. Pham, “NeuroKit2: A Python toolbox for neurophysiological signal processing,” *Behav. Res. Methods*, vol. 53, no. 4, pp. 1689–1696, 2021, doi: 10.3758/s13428-020-01516-y.
- [33] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, “Heart rate variability: standards of measurement, physiological interpretation and clinical use,” *Circulation*, vol. 93, no. 5, pp. 1043–1065, 1996, doi: 10.1161/01.CIR.93.5.1043.