

Proyecto 4: Clasificación Automática de Arritmias Cardíacas a partir de Señales ECG utilizando Redes Neuronales, XGBoost, K-means y SVM

^{1st} Dina Yared Parra Romero
Universidad de Antioquia
Medellín, Colombia
dina.parra@udea.edu.co

^{3rd} Cristian Tamayo Arango
Universidad de Antioquia
Medellín, Colombia
cristian.tamayo@udea.edu.co

^{2nd} Carolina Ruiz Morales
Universidad de Antioquia
Medellín, Colombia
carolina.ruizm@udea.edu.co

Resumen En el proyecto se presenta un sistema de clasificación automática de arritmias a partir de señales ECG. Se utilizaron bases de datos con registros en derivación II, procesadas mediante técnicas multietapa que incluyeron filtrado, extracción de características y clasificación. Se evaluaron tres arquitecturas de redes neuronales, el modelo XGBoost, y se implementaron K-means y SVM. Se obtuvo una precisión superior al 84% con MLP residual, y se identificaron patrones morfológicos robustos para AFIB, SB, SR y SVT. Se discuten también tres dispositivos comerciales con algoritmos diagnósticos basados en ECG.

I. INTRODUCCIÓN

Las enfermedades cardiovasculares (ECV) son responsables de más de 17 millones de muertes anuales a nivel global, lo que representa aproximadamente el 32% de todas las muertes mundiales [1]. Estas patologías, que incluyen infartos agudos de miocardio, arritmias y accidentes cerebrovasculares, muchas veces no presentan síntomas evidentes en sus primeras etapas, lo que hace indispensable el desarrollo de métodos diagnósticos tempranos, accesibles y precisos. El electrocardiograma (ECG) es una herramienta esencial en el diagnóstico clínico de enfermedades cardíacas. Esta técnica, no invasiva y de bajo costo, registra la actividad eléctrica del corazón a través de electrodos ubicados en la superficie del cuerpo, generando señales que reflejan el funcionamiento del sistema de conducción cardíaco [2]. A pesar de su utilidad, la interpretación manual de señales ECG puede verse limitada por la variabilidad fisiológica, artefactos de ruido, y la experiencia del personal médico. Por tanto, se ha incrementado el interés por automatizar el análisis de estas señales mediante técnicas computacionales avanzadas.

La bioingeniería ha aprovechado el auge del aprendizaje automático y el análisis de grandes volúmenes de datos biomédicos para desarrollar modelos capaces de identificar patrones complejos en señales ECG. Técnicas como redes neuronales artificiales, máquinas de soporte vectorial (SVM), XGBoost y algoritmos de agrupamiento como K-means, permiten construir sistemas de clasificación automática que pueden

detectar y discriminar diferentes tipos de arritmias con alto nivel de precisión [3] [4]. Una etapa crítica en estos sistemas es la extracción de características (feature extraction), la cual permite representar las señales ECG en un formato numérico que preserve la información fisiológica relevante, incluso en casos donde desaparecen ciertas ondas del complejo PQRS debido a patologías [5] [6]. Estudios recientes han demostrado que el uso combinado de características temporales, frecuenciales y estadísticas mejora significativamente la capacidad predictiva de los modelos [7].

Este proyecto integra todos estos enfoques con el fin de desarrollar un sistema de clasificación automático de señales ECG utilizando bases de datos especializadas y algoritmos de aprendizaje automático. Se analiza el comportamiento de diversas arquitecturas de red, se construyen matrices de confusión para evaluar el rendimiento y se discute el potencial clínico de cada metodología aplicada.

II. ANTECEDENTES

A. *Optimal Multi-Stage Arrhythmia Classification Approach.*

En el artículo se aborda el problema de la detección automática de arritmias cardíacas a partir del ECG, con el objetivo de alcanzar un nivel de precisión comparable al de un cardiólogo profesional, optimizando un esquema de clasificación multietapa usando registros de ECG de 12 derivaciones, que incluya filtrado de ruido, extracción de características relevantes y la selección del modelo de clasificación óptimo. Dado que las arritmias abarcan distintas alteraciones del ritmo cardíaco, como la fibrilación auricular, las taquicardias supraventriculares o la bradicardia sinusal, es fundamental contar con métodos de detección temprana y precisa para facilitar el inicio oportuno del tratamiento [8].

El método propuesto se desarrolla en varias etapas. Primero, se aplica una reducción de ruido en tres pasos: un filtro Butterworth de baja frecuencia para eliminar ruido de alta frecuencia, un filtrado Robust LOESS para corregir la deriva

de la línea base y la técnica Non-Local Means (NLM) para suprimir el ruido residual, lo que permite filtrar la señal de interferencias comunes como el ruido de red eléctrica, los movimientos del paciente o las contracciones musculares, preservando al máximo la forma verdadera de la onda [8].

Después del filtrado, se realiza la extracción de características. A diferencia de otros enfoques que se limitan a medir amplitudes o duraciones de ondas específicas, aquí se diseñan características que describen tanto la morfología como el comportamiento estadístico de toda la onda PQRS. Se identifican picos y valles locales de la señal (clasificados como parte del complejo QRS, posibles ondas P o T y valles asociados), lo que permite capturar la dinámica completa de cada latido cardíaco [8]. Con estas características se entrenan y comparan múltiples modelos de clasificación, utilizando 19 algoritmos distintos (como árboles de decisión, SVM, redes neuronales y modelos de boosting), junto con distintas estrategias de combinación (como bagging o AdaBoost). El sistema se entrenó con una base de datos que contiene registros de pacientes clasificados en cuatro tipos de ritmos cardíacos: fibrilación auricular (AFIB/AFL), taquicardias supraventriculares (GSVT), bradicardia sinusal (SB) y ritmo sinusal (SR) [8].

1) *¿Qué sucede cuando desaparecen ciertas ondas del complejo PQRS?*: En la práctica clínica es común que algunas ondas del ECG se distorsionen o desaparezcan debido a enfermedades cardíacas. Por ejemplo, en la fibrilación auricular, la onda P puede estar ausente, mientras que en algunas arritmias ventriculares, el complejo QRS puede volverse ancho o irregular. El artículo destaca que un buen sistema automático de análisis debe ser capaz de enfrentar estos casos, por lo tanto, el artículo no se basa únicamente en detectar ondas específicas, sino en extraer relaciones estadísticas y percentiles de los intervalos y magnitudes de la señal, lo que permite seguir obteniendo información útil incluso cuando una onda como la P no está presente. Así, el sistema no depende exclusivamente de que todas las ondas aparezcan, sino que aprovecha la variabilidad de la señal y lo que sí se puede medir para tomar decisiones [8].

En otro estudio, hablando de la fibrilación articular, también se propone que cuando falta la onda P antes de un latido, se puede usar un método que detecta patrones compatibles con fibrilación auricular, y en esos casos, el sistema simplemente no busca la onda P, porque reconoce que no estará. Este tipo de estrategias son muy útiles porque adaptan el análisis a la realidad de cada enfermedad. En lugar de buscar siempre lo mismo, el sistema interpreta lo que hay y se enfoca en otras señales que también indican lo que está pasando, como la irregularidad del ritmo cardíaco. De este modo, se puede seguir detectando bien la enfermedad, incluso si falta parte del trazo del ECG [9].

B. K-means y Máquinas de Vectores de Soporte (SVM)

1) *K-means*: 2.1 K-means es un algoritmo de clasificación no supervisada (clusterización) que agrupa objetos en k grupos basándose en sus características. El agrupamiento se realiza minimizando la suma de distancias entre cada objeto y el centroide de su grupo o cluster. Se suele usar la distancia cuadrática.

El algoritmo consta de tres pasos:

- **Inicialización**: Una vez escogido el número de grupos, k, se establecen k centroides en el espacio de los datos, por ejemplo, escogiéndolos aleatoriamente.
- **Asignación objetos a los centroides**: Cada objeto de los datos es asignado a su centroide más cercano.
- **Actualización centroides**: Se actualiza la posición del centroide de cada grupo tomando como nuevo centroide la posición del promedio de los objetos pertenecientes a dicho grupo [10].

Se repiten los pasos 2 y 3 hasta que los centroides no se mueven, o se mueven por debajo de una distancia umbral en cada paso. El algoritmo K-means tiene como objetivo particionar un conjunto de n observaciones $X = \{x_1, x_2, \dots, x_n\}$ en K clústeres $C = \{C_1, C_2, \dots, C_K\}$, de forma que se minimice la suma de las distancias cuadradas dentro de cada clúster:

$$J = \sum_{i=1}^K \sum_{x_j \in C_i} \|x_j - \mu_i\|^2$$

donde:

- x_j es un vector de características,
- C es el conjunto de puntos asignados al clúster i ,
- μ_i es el centroide del clúster i ,
- K es el número total de clústeres.

2) *Máquinas de Vectores de Soporte (SVM)*: Una Support Vector Machine es un algoritmo de Machine Learning supervisado que se suele utilizar para problemas de clasificación y regresión en aplicaciones de procesamiento de señales, procesamiento del lenguaje natural (PLN), y reconocimiento del habla e imágenes. El objetivo del algoritmo de SVM es encontrar un hiperplano que, en la mejor medida posible, separe los puntos de datos de una clase de los de otra clase. Este hiperplano puede ser una línea para espacio en 2D o un plano para un espacio con n dimensiones, donde n es el número de características de cada observación del conjunto de datos. Pueden existir múltiples hiperplanos que separen las clases de los datos. El hiperplano óptimo, derivado por el algoritmo de SVM, es el que aumenta el margen entre las dos clases. El margen es la anchura máxima de la franja paralela al hiperplano que no contiene puntos de datos en su interior. Los puntos de datos que marcan el límite de esta franja paralela y están más cerca del hiperplano separador son los vectores de soporte. Los vectores de soporte hacen referencia a un subconjunto de las observaciones de entrenamiento que determinan la ubicación del hiperplano separador [11].

El problema de optimización de SVM puede escribirse como:

$$\min_{\mathbf{w}, b, \xi} \left(\frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \right)$$

sujeito a:

$$y_i (\mathbf{w}^T \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

donde:

- ϕ es la transformación del dato al espacio del kernel,
- ξ_i son variables de holgura,
- C es un parámetro de penalización.

C. Equipos comerciales con algoritmos de ayuda diagnóstica en EKG y su análisis desde el curso de bioseñales

En la actualidad, la integración de algoritmos de ayuda diagnóstica en equipos de electrocardiografía (EKG) ha revolucionado la forma en que se diagnostican y monitorean las enfermedades cardíacas. A continuación, se presentan tres ejemplos destacados de dispositivos comerciales que incorporan estas tecnologías, analizando sus funcionalidades desde la perspectiva de la teoría de bioseñales.

1) *GE Healthcare: ECG MAC Series*: GE Healthcare es un líder en el desarrollo de equipos de electrocardiografía, como la serie MAC. Estos dispositivos están equipados con algoritmos avanzados que permiten la detección automática de arritmias y isquemia miocárdica. La serie MAC analiza múltiples derivaciones simultáneamente, lo que facilita la identificación de eventos críticos como la taquicardia ventricular. Desde la teoría de bioseñales, estos equipos aplican técnicas de procesamiento digital de señales para filtrar el ruido y mejorar la calidad de la señal EKG. Utilizan análisis de intervalos y morfología de ondas (P, QRS, T) para extraer características relevantes, lo que permite la clasificación automática de ritmos cardíacos. Este enfoque se basa en la detección de eventos y el análisis de series temporales, conceptos fundamentales en el estudio de bioseñales [12].

2) *Philips: Efficia/IntelliVue*: Philips ofrece dispositivos como la serie Efficia y los monitores IntelliVue, que son ampliamente utilizados en entornos hospitalarios. Estos equipos cuentan con algoritmos de ayuda diagnóstica que detectan arritmias y bloqueos, mostrando una alta sensibilidad y baja tasa de falsas alarmas. Desde la perspectiva de la teoría de bioseñales, los algoritmos de Philips implementan filtros digitales para eliminar artefactos y preservar la información relevante de la señal. Además, utilizan análisis de múltiples derivaciones para mejorar la robustez diagnóstica, fundamentándose en la redundancia y complementariedad de la información en diferentes canales. Este enfoque permite una clasificación automática más precisa, apoyándose en modelos

de aprendizaje automático y reglas heurísticas basadas en la fisiología cardíaca [13].

3) *Mindray: BeneVision y ePM/iPM*: Mindray es otro fabricante relevante que ofrece equipos como la serie BeneVision y los monitores ePM/iPM. Estos dispositivos integran algoritmos para la detección de arritmias y eventos cardíacos críticos, y ofrecen conectividad inalámbrica y análisis en tiempo real. Los algoritmos de Mindray han sido evaluados en estudios clínicos, mostrando resultados competitivos en sensibilidad y especificidad. Desde la teoría de bioseñales, estos equipos emplean técnicas avanzadas de supresión de ruido y análisis de calidad de la señal, descartando segmentos ruidosos antes de realizar el análisis automático. Además, utilizan algoritmos de clasificación basados en aprendizaje automático, entrenados con grandes bases de datos de señales EKG, lo que permite una detección más precisa de patrones anómalos [14].

4) *Dispositivos Wearables: Apple Watch y Otros*: Además de los equipos médicos tradicionales, los dispositivos wearables como el Apple Watch y otros modelos de Fitbit y Samsung han incorporado algoritmos de ayuda diagnóstica para la detección de fibrilación auricular y otras arritmias. Estos dispositivos permiten a los usuarios realizar registros EKG de una sola derivación y utilizan algoritmos validados clínicamente para alertar sobre posibles anomalías. Desde la teoría de bioseñales, estos dispositivos emplean sensores de bioseñales y técnicas de procesamiento digital para filtrar el ruido de movimiento y artefactos ambientales. Utilizan modelos de aprendizaje profundo para analizar la morfología y la variabilidad de la señal EKG, lo que permite una clasificación automática de ritmos cardíacos [15].

III. METODOLOGÍA

El presente trabajo se desarrolló en 4 etapas, cada una orientada a construir un sistema de clasificación automática de arritmias cardíacas a partir de señales ECG. A continuación, se detalla la metodología empleada en los primeros siete numerales del proyecto.

A. Selección del Conjunto de Datos y Ritmos Cardíacos

A partir del análisis comparativo del proyecto anterior, se eligió el conjunto ECGDataDenoised, generado con redes GAN, debido a su mayor calidad y menor ruido.

Se seleccionaron cuatro ritmos cardíacos clínicamente relevantes, estos fueron filtrados en el dataframe, eliminando otras etiquetas no consideradas para el estudio.:

- **Ritmo Sinusal (SR)**: Corresponde al ritmo cardíaco normal, generado de forma regular por el nodo sinoauricular. Se elige ya que puede ser la ritmia de referencia para marcar diferencias con otras arritmias, ya que su

morfología típica (onda P seguida de complejo QRS y onda T, con intervalos regulares) permite contrastar con ritmos patológicos y calibrar la sensibilidad del sistema frente a desviaciones.

- **Fibrilación Auricular (AFIB):** Se elige porque es una de las arritmias más comunes y clínicamente importantes. Se caracteriza por la ausencia de onda P visible, presencia de múltiples ondas de fibrilación y una variabilidad marcada en los intervalos RR con un latido rápido y descoordinado. Representa un caso en el que se pierden componentes clásicos del ECG, lo que desafía tanto la extracción de características como la capacidad de generalización de los clasificadores.
- **Bradicardia Sinusal (SB):** Se elige porque representa un ritmo de origen sinusal pero con frecuencia cardíaca disminuida (generalmente < 60 latidos por minuto). En la bradicardia sinusal el ECG muestra ondas P seguidas de QRS de apariencia normal, con un patrón regular pero a menor frecuencia. Aunque mantiene la morfología típica del ritmo sinusal, los intervalos entre latidos son más largos, lo cual es útil para entrenar modelos que detecten cambios en frecuencia sin alteraciones en la forma de onda.
- **Taquicardia Supraventricular (SVT):** Se elige porque agrupa es una arritmia rápida, la cual puede contrastar con la bradicardia. Su detección es compleja, ya que muchas veces la onda P está superpuesta con el complejo QRS o ausente visualmente, y el ritmo tiende a ser muy regular, lo cual nos permitirá evaluar si el modelo es capaz de reconocer ritmos rápidos y regulares con morfologías menos evidentes.

B. Construcción del Dataframe y Selección de Características

Se integraron características extraídas de proyectos anteriores y del artículo revisado:

- **Proyecto 1:** SDNN y RMSSD (HRV) eliminadas posteriormente por presencia de nulos.
- **Proyecto 2:** DFT (frecuencia pico, energía total), DCT (media y desviación estándar), MFCC (energía y entropía).
- **Proyecto 3:** Frecuencia de máxima potencia (fMP).
- **Del artículo de Zheng et al. (2020)** Se escogieron 2 características las cuales permiten mejorar la robustez del modelo ante señales ECG deformadas o incompletas. Estas fueron *prominencia_QRS* calculada utilizando la función `find_peaks()` de `scipy.signal`, con el argumento `prominence`, para encontrar el pico más prominente de cada latido. Esto se justifica porque el complejo QRS es el más robusto frente a ruido y mantiene su presencia en la mayoría de ritmos.

C. Redes Neuronales: Clasificación Multiclase

Para abordar la tarea de clasificación multiclase de arritmias cardíacas a partir de registros de señales ECG, se diseñaron y

entrenaron cuatro arquitecturas de redes neuronales artificiales, todas implementadas con la biblioteca Keras de TensorFlow. El conjunto de datos fue dividido en un 80% para entrenamiento y un 20% para evaluación. Las etiquetas correspondientes a las clases (AFIB, SB, SR, SVT) fueron codificadas mediante codificación ordinal utilizando `LabelEncoder`, mientras que las características numéricas fueron normalizadas mediante `StandardScaler`, a fin de garantizar una adecuada convergencia durante el entrenamiento. Como métricas de rendimiento se utilizaron la precisión global (accuracy), la matriz de confusión, y el reporte de clasificación (F1-score, precisión y recall por clase), generados con funciones de `sklearn.metrics`.

La primera arquitectura fue una red neuronal multicapa (MLP) básica, constituida por una capa densa de 64 neuronas con función de activación ReLU, seguida de una capa de Dropout del 30% como regularización, y una segunda capa densa de 32 neuronas. La capa de salida fue una capa softmax con cuatro neuronas, correspondientes a las clases del problema. Este modelo básico funcionó como punto de partida para establecer un marco de referencia comparativo para las arquitecturas más complejas.

En segundo lugar, se diseñó una arquitectura más profunda, con mayor capacidad de representación. Este modelo estuvo compuesto por cuatro capas densas consecutivas (128, 64, 32 y 16 neuronas respectivamente), intercaladas con capas de normalización por lotes y Dropout, lo que permitió reducir la covariancia interna de las activaciones y mejorar la generalización del modelo. Esta configuración buscó capturar patrones de mayor complejidad no lineal en los datos.

La tercera variante fue una red con conexión residual, inspirada en los principios de las redes ResNet. En este diseño, se sumó la salida de una capa intermedia a una capa posterior, utilizando la operación `Add()` sobre capas densas de igual dimensión. Esta técnica permitió preservar información relevante a través del flujo hacia capas más profundas, evitando el desvanecimiento del gradiente y facilitando el aprendizaje de redes más profundas sin degradación del rendimiento.

El cuarto modelo consistió en una red neuronal con un mecanismo de atención sobre las características de entrada. Para ello, se incorporó una capa densa con activación softmax que generó un vector de pesos de atención, el cual fue multiplicado elemento a elemento (`Multiply()`) con la entrada original. Esta estrategia permitió que la red ajustara dinámicamente la importancia relativa de cada característica durante el entrenamiento. A continuación, se conectaron capas densas tradicionales con activación ReLU y dropout, manteniendo el diseño modular observado en las redes previas.

En todos los casos, se utilizó como función de pérdida `sparse_categorical_crossentropy`, apropiada para clasificación

multiclase con etiquetas enteras, y como optimizador se empleó Adam en su configuración por defecto. Cada red fue entrenada durante 50 épocas, con una subdivisión del 10% del conjunto de entrenamiento usada como validación interna. Al concluir el entrenamiento, se evaluaron las predicciones sobre el conjunto de prueba y se calcularon las métricas correspondientes, permitiendo comparar objetivamente el desempeño de cada arquitectura.

Además de las pruebas multiclase, se implementaron modelos binarios entre pares de clases, utilizando variantes simplificadas de las redes anteriores. En estas versiones, se reemplazó la capa de salida por una neurona con activación sigmoidea, y la pérdida por binary_crossentropy. Estas pruebas permitieron evaluar la separabilidad individual entre clases específicas, encontrando que ciertas combinaciones como AFIB vs SR eran fácilmente distinguibles (F1-score ≥ 0.96), mientras que otras como SR vs SB presentaban más solapamiento, en concordancia con su cercanía morfológica.

D. Ejemplo del uso de los modelos K means y máquinas de soporte vectorial (SVM)

En este ejemplo se aplicaron técnicas de aprendizaje automático para el análisis de señales ECG, utilizando tanto métodos no supervisados como supervisados. El objetivo fue explorar la capacidad de agrupamiento de los datos sin usar etiquetas y, posteriormente, evaluar el rendimiento de un clasificador entrenado con dichas etiquetas.

El proceso comenzó con una etapa de preprocesamiento. A partir del conjunto de datos `df_procesar`, se separaron las características numéricas de la columna `Rhythm`, la cual contiene las etiquetas diagnósticas correspondientes a los diferentes tipos de ritmo cardíaco. Dado que estas etiquetas se encontraban en formato categórico (como AFIB, SR, SB, etc.), se utilizó `LabelEncoder` para convertirlas a valores numéricos, permitiendo así su utilización por parte de los modelos. Posteriormente, se aplicó un escalado estándar (`StandardScaler`) sobre las características, lo cual es fundamental para algoritmos sensibles a la magnitud de las variables como K-Means y SVM.

Una vez preparados los datos, se implementó el algoritmo K-Means con cuatro clústeres, ya que el número de clases reales presentes en el conjunto de datos es también cuatro. Este método no supervisado tiene como objetivo descubrir agrupamientos naturales en los datos sin utilizar información previa sobre las clases verdaderas. Para evaluar qué tan bien se alineaban los clústeres formados con las etiquetas reales, se calculó el índice de Rand ajustado (Adjusted Rand Index, ARI), una métrica que mide la concordancia entre dos particiones del conjunto de datos. Valores cercanos a 1 indican una alta similitud entre los grupos generados por K-Means y las clases reales.

Para facilitar la interpretación clínica de los resultados del agrupamiento, a cada clúster se le asignó el nombre de la clase real más frecuente dentro de él. Esta asignación se realizó utilizando la moda de las etiquetas presentes en cada grupo. De esta manera, fue posible representar gráficamente los clústeres con nombres reales como AFIB, SR, SVT, etc., lo que proporciona una visualización más comprensible para usuarios del área de la salud.

Con el fin de representar visualmente los resultados, se aplicó Análisis de Componentes Principales (PCA) para reducir la dimensionalidad de las características a dos componentes principales. Esta técnica permite conservar la mayor parte de la varianza original del conjunto de datos y facilita su representación en dos dimensiones. Se generaron dos gráficas: una mostrando los grupos asignados por K-Means con sus nombres asignados, y otra con las etiquetas reales del conjunto de datos. Esta visualización permitió comparar de forma intuitiva la coherencia entre los clústeres obtenidos y las clases reales.

Luego, se procedió a entrenar un modelo supervisado utilizando máquinas de soporte vectorial (SVM) con un núcleo radial (RBF). El modelo fue entrenado utilizando el 80% del conjunto de datos y validado sobre el 20% restante, respetando la distribución original de clases mediante un muestreo estratificado. La SVM busca encontrar un hiperplano óptimo que separe las clases con el mayor margen posible, y es especialmente útil para problemas con alta dimensionalidad.

Para evaluar el desempeño del modelo, se utilizaron métricas como precisión, sensibilidad (recall) y F1-score para cada clase, generadas mediante `classification_report`. Además, se construyó una matriz de confusión que permitió observar visualmente los errores de clasificación cometidos por el modelo. En conjunto, estas métricas ofrecieron una visión cuantitativa y cualitativa del rendimiento del clasificador.

Finalmente, se generó una visualización adicional del modelo SVM aplicando PCA sobre los datos de prueba, donde se representaron los puntos según su clase predicha (color) y su clase real (forma). Esta gráfica permitió observar visualmente si el modelo SVM logró separar correctamente las distintas clases en el espacio proyectado.

IV. ANÁLISIS Y RESULTADOS

A. Análisis de Redes Neuronales: Clasificación Multiclase

En este análisis se evaluó el desempeño de diferentes arquitecturas de redes neuronales para la clasificación automática de arritmias cardíacas a partir de señales de ECG. La base de datos utilizada consistió en 5596 registros clasificados en cuatro categorías clínicas: fibrilación auricular (AFIB),

bradicardia sinusal (SB), ritmo sinusal (SR) y taquicardia supraventricular (SVT). Cada registro fue representado mediante diez características previamente extraídas, entre ellas medidas espectrales, entropía y propiedades del complejo QRS. No obstante, el análisis exploratorio reveló un alto porcentaje de valores nulos en las variables SDNN y RMSSD, los cuales estaban asociados de forma desbalanceada según el tipo de arritmia, tal como se evidencia en la primera gráfica Figura 1. Esta distribución irregular motivó la exclusión de dichas variables del conjunto final de entrenamiento para evitar sesgos en el aprendizaje del modelo.




Fig. 1: Porcentaje de nulos por columna, dividido por tipo de arritmia.

Se evaluaron cuatro arquitecturas: una red neuronal multi-capas base (MLP base), una MLP profunda con mayor cantidad de capas, una MLP con conexiones residuales y una MLP con un mecanismo de atención sobre las entradas. La base de datos se dividió en conjuntos de entrenamiento (80%) y prueba (20%) utilizando muestreo estratificado para preservar la proporción de clases. Los resultados de las redes se analizaron a partir de las respectivas matrices de confusión:




Fig. 2: MLP Base

En el caso del modelo MLP base, se alcanzó una precisión general del 83.04%. Se observó un buen desempeño en la clasificación de SB y SVT, con valores F1 elevados, pero también errores recurrentes al diferenciar entre AFIB y SR.

La matriz de confusión correspondiente muestra confusión significativa entre estas dos clases, lo cual puede deberse a la similitud en sus patrones espectrales Figura 2.

El modelo MLP profundo, con mayor capacidad representacional, no logró mejorar sustancialmente los resultados y presentó señales de sobreajuste. Aunque mantuvo buenos niveles de precisión en SB, su desempeño para AFIB disminuyó ($F1 = 0.65$), y aumentó el número de falsos positivos en SR, como se visualiza en su matriz de confusión. Esto sugiere que el aumento en complejidad no se tradujo en una mejora significativa, probablemente por la limitada cantidad de ejemplos o por redundancia en las características Figura 3.




Fig. 3: MLP profundo

En contraste, la MLP con conexiones residuales ofreció el mejor balance entre precisión y generalización. Su precisión fue del 83.57% y logró estabilizar el desempeño en todas las clases, reduciendo errores en AFIB y manteniendo alto rendimiento en SB y SVT. La matriz de confusión respectiva refleja esta mejora, con mayor concentración de valores en la diagonal principal, especialmente en la clase SR, que mostró un incremento en su F1-score Figura 4.




Fig. 4: MLP Residual

Finalmente, la MLP con atención incorporó un mecanismo que pondera automáticamente la relevancia de cada característica. Aunque su precisión general fue ligeramente inferior (80.89%), su F1-score macro fue competitivo (0.79) y mostró un comportamiento equilibrado entre clases. Se destaca su desempeño en SVT ($F1 = 0.90$) y su capacidad para reducir errores de clasificación cruzada entre SB y SR, como se aprecia en su matriz de confusión. Este resultado sugiere que la atención puede ser útil en contextos donde las características son redundantes o correlacionadas Figura 5.




Fig. 5: MLP con atención

B. Evaluación Comparativa de Modelos Neuronales para la Clasificación Binaria de Ritmos Cardíacos (SB vs SR)

En este segundo escenario se abordó el problema como una clasificación binaria, enfocándose exclusivamente en distinguir entre dos tipos de arritmia: Bradicardia Sinusal (SB) y Ritmo Sinusal (SR). Esta reducción de clases permitió estudiar de manera más específica la capacidad de las redes neuronales para discriminar entre dos patrones clínicamente relevantes, y evaluar si la complejidad del modelo impacta significativamente el desempeño bajo condiciones de menor ambigüedad.

Se compararon cuatro arquitecturas de redes neuronales: un perceptrón multicapa base (MLP simple), una MLP profunda, una MLP con conexiones residuales y una red con un mecanismo de atención sobre las características. En todos los casos, se utilizó un conjunto de entrenamiento con el 80% de los datos y un conjunto de prueba con el 20%, manteniendo la proporción original de clases mediante muestreo estratificado.

El primer modelo, el MLP simple, alcanzó una precisión en prueba de 89.3%, clasificando correctamente 506 instancias de SB y 223 de SR, según se observa en la primera matriz de confusión. Su F1-score fue de 0.92 para SB y 0.84 para SR, lo que evidencia un leve sesgo a favor de la clase mayoritaria (SB). A pesar de ello, se observa un balance

general aceptable, especialmente considerando la simplicidad del modelo Figura 6.




Fig. 6: MLP simple

El MLP profundo, que incorpora un mayor número de capas y neuronas, obtuvo una precisión muy similar (89.4%), con una mejora marginal en la clasificación de la clase minoritaria. Como muestra su matriz de confusión, logró clasificar correctamente 501 instancias de SB y 241 de SR, lo cual incrementó el recall y el F1-score para SR a 0.85, manteniéndose estable en SB ($F1 = 0.92$). Esto sugiere que una arquitectura más profunda puede ayudar a capturar mejor las particularidades del ritmo sinusal normal, que tiende a confundirse con SB Figura 7.




Fig. 7: MLP profundo

Por su parte, el modelo con conexión residual también alcanzó 89.0% de precisión, con una matriz de confusión equilibrada: 502 aciertos en SB y 230 en SR. Su F1-score fue de 0.92 (SB) y 0.84 (SR). Aunque su desempeño fue casi idéntico al de la MLP base, la menor dispersión en los errores sugiere que las conexiones residuales estabilizan el aprendizaje durante el entrenamiento y podrían aportar robustez ante ligeras variaciones del conjunto de entrada Figura 8.




Fig. 8: MLP residual

La última arquitectura evaluada fue la red con atención, que incluye una capa que pondera dinámicamente la importancia de cada característica durante la predicción. Esta red logró una precisión en prueba del 89.2%, con 492 aciertos en SB y 231 en SR, como se observa en su matriz correspondiente. Su F1-score fue de 0.91 (SB) y 0.85 (SR), muy similar al modelo profundo. La ventaja de esta red radica en su interpretabilidad: el mecanismo de atención permite visualizar qué características tienen mayor peso en la clasificación, lo cual resulta especialmente útil en contextos clínicos Figura 9.




Fig. 9: MLP con atención

En términos comparativos, todos los modelos mostraron un rendimiento altamente competitivo y estable al reducir el problema a dos clases. Las precisiones en prueba superaron consistentemente el 89%, en contraste con el 82–84% observado en la clasificación multiclase original. Esta mejora se explica por la simplificación del espacio de decisión, que facilita a las redes identificar patrones discriminativos con mayor claridad cuando solo deben diferenciar entre dos tipos de ritmo.

Aunque las diferencias en las métricas globales fueron mínimas, sí se observaron variaciones en la sensibilidad hacia

la clase minoritaria (SR). El modelo profundo y el de atención destacaron por su mayor recall en esta clase, lo cual podría ser crucial en aplicaciones clínicas donde se prioriza evitar falsos negativos en diagnósticos de ritmo sinusal normal.

C. Desempeño del modelo XGBoost en la clasificación de arritmias

El modelo de clasificación basado en XGBoost (Extreme Gradient Boosting) alcanzó un desempeño sobresaliente en el contexto de clasificación multiclase de señales ECG, logrando una precisión en prueba del 87.05%, superior a la de todas las arquitecturas de redes neuronales evaluadas previamente. Este resultado pone de manifiesto la eficiencia de los modelos basados en árboles de decisión potenciados, especialmente cuando se aplican a datos tabulares con características numéricas predefinidas.

De acuerdo con la matriz de confusión, el modelo mostró un desempeño particularmente sólido en la identificación de ritmos SB y SR, con recalls de 0.96 y 0.84 respectivamente, reflejando una baja tasa de falsos negativos. Asimismo, XGBoost logró un F1-score de 0.87 para SVT y un recall de 0.92, lo cual es notable considerando que esta clase tiene menor representación en el conjunto de datos. La correcta clasificación de casos minoritarios como SVT evidencia la capacidad del modelo para manejar desbalance sin requerir técnicas adicionales de ponderación o muestreo Figura 10.




Fig. 10: Matriz de confusión- XGBoost

Por otro lado, la clase AFIB continuó siendo la más problemática, con un recall de 0.65. El modelo confundió numerosos casos de AFIB con SR y SB, como se observa en la dispersión de la matriz. Este fenómeno puede explicarse por solapamientos en las características espectrales extraídas, ya que en muchas ocasiones las diferencias entre AFIB y SR no se reflejan claramente en medidas estadísticas simples. En comparación con las redes neuronales (MLP base, profundo, residual y con atención), XGBoost superó a todos los modelos en las tres métricas clave: precisión, macro F1 y F1 ponderado. En particular, obtuvo un macro F1 de 0.84 y un weighted

F1 de 0.87, valores que reflejan tanto buen desempeño en clases minoritarias como una distribución equilibrada en la clasificación general Tabla I.

TABLE I: Desempeño del modelo XGBoost en la clasificación de arritmias.

Modelo	Precisión Prueba	Macro F1	Weighted F1
MLP Base	0.8277	0.81	0.82
MLP Profundo	0.8241	0.78	0.82
MLP Residual	0.8384	0.81	0.83
Red con Atención	0.8241	0.80	0.82
XGBoost	0.8705	0.84	0.87

Una de las principales ventajas observadas fue la simplicidad en la implementación de XGBoost. A diferencia de las redes neuronales, no requiere normalización estricta de las entradas, ni sintonización de parámetros complejos como tasas de aprendizaje, dropout o activaciones no lineales. Además, presentó una curva de aprendizaje más rápida y menos sensible a la arquitectura de entrada, lo que facilita su uso en entornos clínicos donde la interpretabilidad y eficiencia son deseables.

Cabe mencionar que el modelo alcanzó una precisión del 100% en el conjunto de entrenamiento, lo cual sugiere un potencial sobreajuste. Sin embargo, el rendimiento estable en el conjunto de prueba (87.05%) indica que la generalización no se vio comprometida en este caso, posiblemente gracias al efecto de regularización interna del algoritmo.

D. Discusión de resultados: K-Means y SVM

Al comparar los resultados obtenidos con los algoritmos K-Means y SVM aplicados al conjunto de datos de señales ECG, se evidencian diferencias importantes en su capacidad para separar las clases.

En el caso de K-Means, la visualización con PCA muestra que el algoritmo logró cierta agrupación coherente para algunas clases, especialmente para SVT, que se concentró de forma clara en una región del espacio. Sin embargo, AFIB, SB y SR presentaron un alto grado de solapamiento, generando confusiones evidentes entre estos grupos. Aunque a cada clúster se le asignó el nombre de la clase mayoritaria, la coincidencia con las etiquetas reales fue limitada, lo cual se esperaba dado que K-Means no utiliza información supervisada. En resumen, el agrupamiento fue aceptable para clases bien diferenciadas (como SVT), pero poco preciso para ritmos más similares Figura 11.




Fig. 11: Modelo K-Means

Por otro lado, el modelo SVM mostró un desempeño superior. La matriz de confusión evidencia una clasificación precisa de SB (502 aciertos) y SVT (94 aciertos), con una clara mejora respecto a K-Means en todas las clases. Aunque AFIB continúa siendo la clase con mayor nivel de error, el modelo logró separar de forma efectiva la mayoría de las instancias, con una reducción notable en los falsos positivos hacia SR y SB en comparación con el agrupamiento anterior. SR también alcanzó un buen desempeño (210 clasificaciones correctas), a pesar de que sigue siendo una clase que tiende a confundirse con AFIB Figura 12.




Fig. 12: Matriz de confusión SMV

En conjunto, los resultados confirman que SVM supera ampliamente a K-Means en precisión y consistencia cuando se cuenta con etiquetas reales, especialmente en clases con fronteras poco definidas. K-Means, en cambio, fue útil como herramienta de análisis exploratorio, permitiendo visualizar patrones generales, pero no logró una separación fiable de clases similares.

V. CONCLUSIONES

Las redes neuronales evaluadas demostraron ser modelos sólidos para la clasificación de arritmias, alcanzando precisiones entre 82% y 84%. La arquitectura con conexiones residuales se destacó como la más robusta entre las variantes propuestas, logrando un mejor equilibrio entre precisión y F1-score, especialmente para clases difíciles como SR y SVT. Si

bien los modelos profundos y con atención ofrecieron ventajas específicas en sensibilidad o interpretabilidad, no superaron consistentemente al modelo residual en métricas globales. Estos resultados confirman que, con una adecuada configuración, las redes neuronales pueden ofrecer un desempeño competitivo para tareas clínicas de clasificación automática, aunque su eficacia depende fuertemente de la arquitectura y el balance de clases.

XGBoost demostró ser una alternativa altamente efectiva y competitiva frente a las redes neuronales profundas, especialmente en problemas de clasificación con datos estructurados y numéricos como en este caso. Si bien las redes neuronales ofrecieron una arquitectura más flexible para la exploración de distintas configuraciones (conexiones residuales, atención, capas profundas), XGBoost ofreció un mejor equilibrio entre rendimiento, simplicidad de implementación y capacidad de generalización. Por tanto, se concluye que, para esta tarea de clasificación multiclase de arritmias cardíacas con 10 características extraídas, XGBoost fue el modelo con mejor desempeño global, especialmente en términos de precisión, f1-score y robustez frente a clases desbalanceadas.

El ejemplo aplicado con K-Means y SVM evidenció de forma clara las ventajas del aprendizaje supervisado sobre el no supervisado en tareas de clasificación médica. Mientras que K-Means permitió explorar la estructura interna del espacio de características, su rendimiento fue limitado debido al solapamiento entre clases como AFIB, SB y SR. En contraste, el modelo SVM logró una clasificación mucho más precisa y balanceada, destacándose en clases como SB y SVT. Esto confirma que, cuando se cuenta con etiquetas confiables, los modelos supervisados como SVM son notablemente más efectivos y adecuados para aplicaciones diagnósticas que requieren alta precisión.

REFERENCES

- [1] World Health Organization, "Cardiovascular diseases (CVDs)," 2021. [En línea]. Disponible: <https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>
- [2] P. W. Macfarlane, *Comprehensive Electrocardiology*. Springer, 2010.
- [3] S. Kiranyaz, T. Ince, y M. Gabbouj, "Real-Time Patient-Specific ECG Classification by 1-D Convolutional Neural Networks," *IEEE Trans. Biomed. Eng.*, vol. 63, no. 3, pp. 664–675, mar. 2016.
- [4] A. Al-Fahoum y A. Al-Fraihat, "Methods of ECG Signal Features Extraction Using Linear Analysis in Frequency and Time-Frequency Domains," *ISRN Biomed. Eng.*, vol. 2014, pp. 1–9, 2014.
- [5] M. J. Islam *et al.*, "Heart disease prediction using deep learning approach from ECG signal," *Health Inf. Sci. Syst.*, vol. 10, no. 1, pp. 1–14, 2022.
- [6] A. Llamedo y J. P. Martínez, "Heartbeat classification using feature selection driven by database generalization criteria," *IEEE Trans. Biomed. Eng.*, vol. 58, no. 3, pp. 616–625, 2011.
- [7] S. Kachuee, S. Fazeli, y M. Sarrafzadeh, "ECG heartbeat classification: A deep transferable representation," en *Proc. IEEE Int. Conf. Healthcare Informatics (ICHI)*, 2018, pp. 443–444.
- [8] "Deep learning-based arrhythmia classification using long-term wearable ECG monitoring," *Scientific Reports*, 2020. [En línea]. Disponible: <https://www.nature.com/articles/s41598-020-59821-7>
- [9] "A review of ECG signal processing and analysis techniques," *Scientific Reports*, 2022. [En línea]. Disponible: <https://www.nature.com/articles/s41598-022-10656-4>

- [10] "K-Means Clustering Algorithm – from Wolfram MathWorld," *Wolfram MathWorld*. [En línea]. Disponible: <https://mathworld.wolfram.com/K-MeansClusteringAlgorithm.html>. Accedido: 5 de julio de 2025.
- [11] MathWorks, "Support Vector Machine (SVM)," *MathWorks*. [En línea]. Disponible: <https://la.mathworks.com/discovery/support-vector-machine.html>
- [12] MathWorks, "Support Vector Machine (SVM)," *MathWorks*. [En línea]. Disponible: <https://la.mathworks.com/discovery/support-vector-machine.html>
- [13] "Explorar los productos Philips," *Philips*. [En línea]. Disponible: <https://www.philips.com.co/healthcare/solutions/patient-monitoring/continuous-patient-monitoring-systems>. Accedido: 8 de julio de 2025.
- [14] "Monitor de pacientes: Serie ePM - Mindray," *Mindray*. [En línea]. Disponible: <https://www.mindray.com/co/products/patient-monitoring/continuous-patient-monitoring/epm-series>. Accedido: 8 de julio de 2025.
- [15] "Wearable Devices for Arrhythmia Detection: Advancements and Clinical Implications - PMC," *PubMed Central*. [En línea]. Disponible: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12074175/>. Accedido: 8 de julio de 2025.